NLP Pipeline Master Interview Guide

ন্যাচারাল ল্যাঙ্গুয়েজ প্রসেসিং (NLP) এন্ড-টু-এন্ড পাইপলাইনের পূর্ণাঙ্গ ইন্টারভিউ প্রশ্ন ও উত্তর

১. ডেটা অ্যাকুইজিশন (Data Acquisition)

প্রশ্ন ১: ডেটা অ্যাকুইজিশন (Data Acquisition) বলতে কী বোঝেন?

উত্তর: ডেটা অ্যাকুইজিশন হলো কোনো নির্দিষ্ট NLP প্রজেক্টের সমস্যা সমাধানের লক্ষ্যে বিভিন্ন উৎস থেকে কাঁচা (Raw) টেক্সচুয়াল ডেটা অনুসন্ধান, সংগ্রহ, ফিল্টার এবং সিস্টেমে সংরক্ষণের ধারাবাহিক প্রক্রিয়া। এটি পাইপলাইনের প্রথম ও সবচেয়ে গুরুত্বপূর্ণ ভিত্তিপ্রস্তর।

প্রশ্ন ২: এনএলপিতে আমাদের ডেটা সংগ্রহের প্রয়োজন কেন?

উত্তর: মেশিন লার্নিং বা ডিপ লার্নিং অ্যালগরিদমগুলো স্বয়ংক্রিয়ভাবে শেখার জন্য প্রচুর উদাহরণের ওপর নির্ভর করে।

- **প্যাটার্ন শিখন:** ভাষার ব্যাকরণ, কনটেক্সট এবং সেমান্টিক সম্পর্ক বোঝার জন্য বিপুল ডেটা আবশ্যক।
- **মডেলের নির্ভুলতা:** ডেটার পরিধি ও বৈচিত্র্য যত বেশি হবে, মডেলটির রিয়েল-ওয়ার্ল্ড পারফরম্যান্স ও জেনারেলাইজেশন ক্ষমতা তত উন্নত হবে।

প্রশ্ন ৩: একটি NLP প্রজেক্টের জন্য কোথা থেকে ডেটা সংগ্রহ করা যায়?

উত্তর: প্রধানত ৫টি উৎস থেকে ডেটা সংগ্রহ করা হয়:

1. **ওপেন ডেটাসেট রিপোজিটরি:** Kaggle, Hugging Face Datasets, UCI Machine Learning Repository।
2. **ওয়েব স্ক্র্যাপিং (Web Scraping):** BeautifulSoup, Scrapy বা Selenium ব্যবহার করে ওয়েবসাইট থেকে তথ্য নেওয়া।
3. **এপিআই (APIs):** Twitter API, Reddit API, Wikipedia API ইত্যাদির মাধ্যমে রিয়েল-টাইম তথ্য সংগ্রহ।
4. **পাবলিক ডেটা ওয়েব ক্রলিং:** Common Crawl-এর মতো বিশ্বব্যাপী আর্কাইভ।
5. **অভ্যন্তরীণ ডেটা (Internal Data):** কোম্পানির নিজস্ব ডাটাবেস, কাস্টমার সাপোর্ট চ্যাট লোগ বা ট্রানজেকশন হিস্ট্রি।

প্রশ্ন ৪: একটি ডেটাসেটকে ভালো ও আদর্শ ডেটাসেট বানায় কোন বিষয়গুলো?

উত্তর: একটি মানসম্মত ডেটাসেটের প্রধান চার বৈশিষ্ট্য:

- **প্রাসঙ্গিকতা (Relevance):** ডেটা যেন সরাসরি ব্যবসায়িক বা টেকনিক্যাল সমস্যার প্রতিনিধিত্ব করে।
- **পর্যাপ্ত পরিমাপ ও বৈচিত্র্য (Quantity & Diversity):** বিভিন্ন ডোমেইন, স্টাইল ও সেন্টিমেন্টের সমন্বয় থাকা।
- **লেবেলের নির্ভুলতা (High-Quality Labels):** সুপারভাইজড লার্নিংয়ের জন্য গোল্ড-স্ট্যান্ডার্ড সঠিক লেবেলিং।
- **পক্ষপাতহীনতা (Unbiasedness):** ডেটাতে কোনো নির্দিষ্ট শ্রেণী, লিঙ্গ বা মতাদর্শের পক্ষপাত না থাকা।

২. টেক্সট প্রিপারেশন (Text Preparation)

প্রশ্ন ৫: টেক্সট প্রিপারেশন (Text Preparation) বলতে কী বোঝায়?

উত্তর: বিভিন্ন উৎস থেকে সংগৃহীত অসংগঠিত ও অগোছালো কাঁচা টেক্সটকে মেশিনের প্রক্রিয়াকরণ উপযোগী, সুসংগঠিত ও পরিষ্কার ফরম্যাটে রূপান্তর করার সামগ্রিক ধাপকে টেক্সট প্রিপারেশন বলে। এটি টেক্সট ক্লিনিং ও টেক্সট প্রিপ্রসেসিংয়ের সমষ্টি।

টেক্সট প্রিপারেশন (চলমান)

প্রশ্ন ৬: টেক্সট ক্লিনিং (Text Cleaning) কেন অত্যন্ত গুরুত্বপূর্ণ?

উত্তর: "Garbage In, Garbage Out" নীতি অনুযায়ী, র টেক্সটে প্রচুর নয়েজ (HTML ট্যাগ, অপ্রয়োজনীয় ক্যারেক্টার, স্প্যাম) থাকে। ক্লিনিং না করলে মডেল ভুল ফিচার শেখে, ডাইমেনশনালিটি বৃদ্ধি পায় এবং মডেলের নির্ভুলতা ব্যাপকভাবে হ্রাস পায়।

প্রশ্ন ৭: র টেক্সট ক্লিনিংয়ে সাধারণত কোন কোন পদক্ষেপ নেওয়া হয়?

উত্তর: সাধারণ ক্লিনিং ধাপগুলো নিচে দেওয়া হলো:

- **HTML & URL Removal:** `<p>`, `<div>` ট্যাগ এবং ওয়েবসাইট লিঙ্ক মুছে ফেলা।
- **Lowercase Conversion:** 'Apple' এবং 'apple' যেন দুটি ভিন্ন শব্দ হিসেবে গণ্য না হয়।
- **Punctuation & Special Character Removal:** জ্যোতিচিহ্ন (`!@#$%^&*`) বাদ দেওয়া।
- **Number Removal:** যদি সংখ্যাগুলো প্রসঙ্গের জন্য গুরুত্বপূর্ণ না হয়।
- **Whitespace Normalization:** অতিরিক্ত স্পেস, ট্যাব বা নিউলাইন মুছে ফেলা।

প্রশ্ন ৮: টেক্সট প্রিপ্রসেসিং (Text Preprocessing) কী?

উত্তর: টেক্সটকে ক্লিন করার পর সেটিকে ছোট ছোট ভাষাগত উপাদানে রূপান্তর এবং ব্যাকরণগত মানকীকরণের (Normalization) মাধ্যমে ফিচার এক্সট্রাকশনের উপযোগী করার নামই টেক্সট প্রিপ্রসেসিং।

প্রশ্ন ৯: প্রধান প্রিপ্রসেসিং টেকনিকগুলো কী কী? বিস্তারিত বলুন।

- **Tokenization:** বাক্যকে ভেঙে ছোট ছোট টোকেনে (শব্দ বা সাব-ওয়ার্ড) ভাগ করা।
- **Stop-words Removal:** অতিরিক্ত ব্যবহৃত কিন্তু কম তথ্যবহুল শব্দ (যেমন: is, the, এবং, কিন্তু) বাদ দেওয়া।
- **Stemming:** অ্যালগরিদমিক নিয়মে শব্দের মূল রূপ বা মূল কাণ্ডে নিয়ে যাওয়া (যেমন: running -> run, better -> bet [কখনও ভুল শব্দ তৈরি হয়])।
- **Lemmatization:** অভিধান বা ব্যাকরণগত অর্থ বজায় রেখে সঠিক মূল শব্দে (Lemma) রূপান্তর করা (যেমন: better -> good)।

প্রশ্ন ১০: কখন অ্যাডভান্সড প্রিপ্রসেসিং টেকনিক প্রয়োজন হয়?

উত্তর: যখন বাক্যের গভীর অর্থ ও গঠন বোঝা জরুরি হয়। যেমন: **POS Tagging** (পদ প্রকরণ চিহ্নিতকরণ), **Named Entity Recognition - NER** (ব্যক্তি বা স্থানের নাম শনাক্তকরণ), এবং **Dependency Parsing** (শব্দের মধ্যকার ব্যাকরণগত সম্পর্ক নির্ধারণ)।

৩. রেগুলার এক্সপ্রেশন (Regular Expressions - Regex)

প্রশ্ন ১১: Regular Expression (Regex) কী এবং এটি NLP-তে কেন ব্যবহৃত হয়?

উত্তর: Regex হলো টেক্সটের মধ্যে নির্দিষ্ট ক্যারেক্টার প্যাটার্ন খোঁজা বা ম্যাচ করার এক বিশেষ সিনট্যাক্স। NLP-তে টেক্সট ফিল্টারিং, প্যাটার্ন এক্সট্রাকশন এবং দ্রুত ও নিখুঁত ক্লিনিংয়ের জন্য Regex ব্যবহৃত হয়।

প্রশ্ন ১২: Regex Pattern কী?

উত্তর: বিশেষ প্রতীক ও ক্যারেক্টারের সমন্বয়ে গঠিত একটি নিয়ম বা সিকোয়েন্স, যা সার্চ ইঞ্জিনকে নির্দেশ করে টেক্সট থেকে ঠিক কোন ধরণের স্ট্রিং খুঁজে বের করতে হবে (যেমন: কেবল ডিজিট নাকি নির্দিষ্ট অক্ষরের বিন্যাস)।

রেগুলার এক্সপ্রেশন (চলমান)

প্রশ্ন ১৩: Regex প্রতীকগুলোর (., *, +, ?, ^, $) কাজ কী?

- `.` (Dot): নিউলাইন বাদে যেকোনো একক ক্যারেক্টার নির্দেশ করে।
- `*` (Star): পূর্ববর্তী ক্যারেক্টার **০ বা ততোধিক বার** থাকতে পারে।
- `+` (Plus): পূর্ববর্তী ক্যারেক্টার **১ বা ততোধিক বার** অবশ্যই থাকতে হবে।
- `?` (Question): পূর্ববর্তী ক্যারেক্টার **০ বা ১ বার** (অপশনাল)।
- `^` (Caret): টেক্সট বা লাইনের **শুরু** নির্দেশ করে।
- `$` (Dollar): টেক্সট বা লাইনের **শেষ** নির্দেশ করে।

প্রশ্ন ১৪: Regex দিয়ে ইমেইল, ফোন নম্বর বা URL কীভাবে খুঁজে বের করবেন?

উত্তর: নির্দিষ্ট প্যাটার্ন তৈরি করে সার্চ করা হয়:

- **Email Pattern:** `r'[a-zA-Z0-9._%+-]+@[a-zA-Z0-9.-]+\.[a-zA-Z]{2,}'`
- **Phone Number Pattern:** `r'(\+?\d{1,3}[-.\s]?)?\(?\d{3}\)?[-.\s]?\d{3}[-.\s]?\d{4}'`
- **URL Pattern:** `r'https?://[^\s]+'`

প্রশ্ন ১৫: টেক্সট ক্লিনিংয়ে Regex কীভাবে সাহায্য করে?

উত্তর: `re.sub()` ফাংশন ব্যবহার করে নির্দিষ্ট ক্ষতিকারক ক্যারেক্টার, অতিরিক্ত স্পেস, হ্যাশট্যাগ, ইমোজি বা স্পেশাল স্যাম্বল এক ক্লিকেই মুছে ফেলা বা পরিবর্তন করা যায়।

৪. ফিচার ইঞ্জিনিয়ারিং (Feature Engineering)

প্রশ্ন ১৬: ফিচার ইঞ্জিনিয়ারিং (Feature Engineering) বলতে কী বোঝেন?

উত্তর: মানুষের বোধগম্য টেক্সট ডেটাকে ম্যাথমেটিক্যাল বা নিউমেরিক্যাল ভেক্টরে (Numerical Vectors) রূপান্তর করার কৌশলকে ফিচার ইঞ্জিনিয়ারিং বা Text Vectorization বলে।

প্রশ্ন ১৭: মেশিন লার্নিং মডেল কেন সরাসরি র টেক্সট নিয়ে কাজ করতে পারে না?

উত্তর: এমএল মডেলগুলো মূলত বীজগণিত, ম্যাট্রিক্স গুণন ও ক্যালকুলাসের গাণিতিক সূত্রের ওপর প্রতিষ্ঠিত। তারা কেবল ইনপুট হিসেবে সংখ্যা (Numbers/Tensors) গ্রহণ করে। তাই টেক্সটকে ভেক্টরে রূপান্তর করা বাধ্যতামূলক।

প্রশ্ন ১৮: কখন কোন টেক্সট রিপ্রেজেন্টেশন টেকনিক বেছে নেবেন?

- **One-Hot Encoding:** ছোট ভোকাবুলারি এবং ক্যাটাগরিক্যাল ডেটার জন্য উপযোগী, তবে এটি স্পার্স ভেক্টর তৈরি করে।
- **Bag of Words (BoW):** সাধারণ ক্লাসিফিকেশনের জন্য ভালো, কিন্তু এটি শব্দের ক্রম (Word order) ও কনটেক্সট হারায়।
- **TF-IDF:** গুরুত্বপূর্ণ শব্দগুলোকে প্রাধান্য দেওয়ার জন্য চমৎকার (যেমন: স্প্যাম ফিল্টারিং বা ডকুমেন্ট ক্লাসিফিকেশন)।
- **Word Embeddings (Word2Vec, GloVe):** যখন শব্দের অর্থ ও সেমান্টিক মিল (Contextual Similarity) ধরে রাখা প্রয়োজন।
- **Transformer Embeddings (BERT):** জটিল ডিপ লার্নিং টাস্ক যেখানে ডাইনামিক কনটেক্সট (একই শব্দের ভিন্ন অর্থ) বোঝা জরুরি।

৫. মডেলিং (Modelling)

প্রশ্ন ১৯: মডেলিং (Modelling) বলতে কী বোঝেন?

উত্তর: সংখ্যাসূচক ভেক্টর ফিচারগুলোকে উপযুক্ত মেশিন লার্নিং বা ডিপ লার্নিং অ্যালগরিদমে ইনপুট দিয়ে অ্যালগরিদমকে ডেটার ভেতরের প্যাটার্ন শেখানো এবং একটি প্রেডিক্টিভ মডেল তৈরি করার প্রক্রিয়াকে মডেলিং বলে।

প্রশ্ন ২০: একটি নির্দিষ্ট সমস্যার জন্য কীভাবে উপযুক্ত মেশিন লার্নিং অ্যালগরিদম বেছে নেবেন?

উত্তর: অ্যালগরিদম নির্বাচন ৪টি বিষয়ের ওপর নির্ভর করে:

1. **ডেটার আকার (Data Size):** ডেটা কম হলে Naive Bayes/Logistic Regression, বিশাল ডেটা হলে Deep Learning (Transformer)।
2. **সমস্যার প্রকৃতি (Problem Nature):** ক্লাসিফিকেশন, সিকোয়েন্স লেবেলিং নাকি জেনারেশন টাস্ক।
3. **ব্যাখ্যাযোগ্যতা (Interpretability):** ব্যবসায়িক ক্ষেত্রে মডেলের সিদ্ধান্ত ব্যাখ্যা করা জরুরি হলে ক্লাসিক্যাল মডেল ভালো।
4. **কম্পিউটেশনাল রিসোর্স:** ট্রেনিং ও ইনফারেন্সের জন্য GPU/CPU পাওয়ারের প্রাপ্যতা।

প্রশ্ন ২১: টেক্সট ক্লাসিফিকেশনের জন্য আপনি কোন অ্যালগরিদম ব্যবহার করবেন এবং কেন?

উত্তর: Baseline হিসেবে **Multinomial Naive Bayes** বা **Logistic Regression** (TF-IDF এর সাথে) ব্যবহার করব কারণ এগুলো দ্রুত কাজ করে। তবে সেরা ফলাফলের জন্য ফাইন-টিউনড **BERT / RoBERTa** ব্যবহার করব, কারণ এগুলো বাই-ডিরেকশনাল কনটেক্সট বুঝতে পারে।

প্রশ্ন ২২: ট্রেনিং (Training) এবং টেস্টিং (Testing) মডেলের মধ্যে পার্থক্য কী?

উত্তর: Training: মডেলকে পরিচিত ডেটা (In-sample data) ও লেবেল দিয়ে প্যাটার্ন শিখতে দেওয়া হয়। **Testing:** মডেলের সম্পূর্ণ অজানা নতুন ডেটাতে (Out-of-sample data) কেমন পারফর্ম করছে তা পরীক্ষা করে আসল পারফরম্যান্স মাপা হয়।

৬. মূল্যায়ন (Evaluation) — ইনট্রিন্সিক (Intrinsic)

প্রশ্ন ২৩: মডেল মূল্যায়ন (Model Evaluation) কী এবং কেন এটি প্রয়োজন?

উত্তর: বিভিন্ন টেস্ট মেট্রিকের সাহায্যে মডেলের প্রেডিকশনের সঠিকতা যাচাই করাকে মডেল মূল্যায়ন বলে। এটি নিশ্চিত করে যে মডেলটি ডেটা মুখস্থ (Overfitting) করেনি, বরং নতুন ডেটাতেও সঠিকভাবে কাজ করছে।

প্রশ্ন ২৪: Accuracy, Precision, Recall এবং F1-Score বলতে কী বোঝায়?

- **Accuracy:** মোট অনুমানের মধ্যে কতগুলো সঠিক হয়েছে। `(TP + TN) / (TP + TN + FP + FN)`
- **Precision:** মডেল যতগুলোকে 'পজিটিভ' বলেছে, তার মধ্যে সত্যি পজিটিভ কতগুলো। `TP / (TP + FP)` [False Positive কমানো যেখানে লক্ষ্য]।
- **Recall:** আসলেও যতগুলো পজিটিভ ছিল, তার মধ্যে মডেল কতগুলোকে ধরতে পেরেছে। `TP / (TP + FN)` [False Negative কমানো যেখানে লক্ষ্য]।
- **F1-Score:** Precision এবং Recall-এর হারমোনিক গড় (Harmonic Mean)। `2 * (Precision * Recall) / (Precision + Recall)`।

ইভালুয়েশন — ইনট্রিন্সিক ও এক্সট্রিন্সিক (Extrinsic)

প্রশ্ন ২৫: Accuracy কখন ভালো মেট্রিক নয়?

উত্তর: **Imbalanced Dataset**-এর ক্ষেত্রে Accuracy মারাত্মক ভুল ধারণা দেয়। উদাহরণস্বরূপ, ৯৯টি নরমাল ইমেইল এবং ১টি স্প্যাম ইমেইলের মধ্যে মডেল যদি সবগুলোকে 'নরমাল' বলে, তবে Accuracy ৯৯% হলেও স্প্যাম ধরার ক্ষমতা ০%! এ ক্ষেত্রে F1-score বা ROC-AUC ব্যবহার করতে হয়।

প্রশ্ন ২৬: Extrinsic Evaluation কী? একটি মডেল কি ভালো Accuracy পেয়েও বাস্তবে ব্যর্থ হতে পারে?

উত্তর: ফাইনাল অ্যাপ্লিকেশনে (যেমন: কাস্টমার সাপোর্ট বট বা সেলস কনভার্সন) মডেল ব্যবহারের পর ব্যবসায়িক ইমপ্যাক্ট মাপা হলো Extrinsic Evaluation। হ্যা, ব্যর্থ হতে পারে! অফলাইনে ভালো Accuracy পেলেও অতিরিক্ত ইনফারেন্স লেটেন্সি (Latency), ইউজারদের অপ্রাসঙ্গিক ভাষা ব্যবহার বা বিজনেস লজিকের সাথে অমিল থাকলে বাস্তবে মডেলটি ফেইল করে।

৭. ডেপ্লয়মেন্ট (Deployment)

প্রশ্ন ২৭: Model Deployment কী, কেন প্রয়োজন এবং কীভাবে ব্যবহারকারী ইন্টারঅ্যাক্ট করে?

উত্তর: প্রশিক্ষিত মডেলকে প্রোডাকশন এনভায়রনমেন্টে (Server/Cloud) হোস্ট করা যেন ব্যবহারকারীরা রিয়েল-টাইমে সুবিধা পেতে পারে। ব্যবহারকারীরা REST API (FastAPI/Flask), gRPC বা UI (Streamlit/React Web App) এর মাধ্যমে ইনপুট পাঠিয়ে আউটপুট দেখতে পায়।

প্রশ্ন ২৮: ডেপ্লয়মেন্টের পর কী কী চ্যালেঞ্জ হতে পারে?

উত্তর: হাই-ট্রাফিক লোডে স্কেলেবিলিটি সমস্যা, মেমোরি লিক, লেটেন্সি বৃদ্ধি, সার্ভার ডাউনটাইম এবং সিকিউরিটি থ্রেট।

৮. মনিটরিং (Model Monitoring)

প্রশ্ন ২৯: Model Monitoring বলতে কী বোঝেন?

উত্তর: প্রোডাকশনে লাইভ ডেপ্লয় করা মডেলের সিস্টেম হেলথ, প্রসেসিং স্পিড, ইনপুট ডেটার ধরন এবং সময়ের সাথে প্রেডিকশনের সঠিকতা ও কোয়ালিটি নিরবচ্ছিন্নভাবে ট্র্যাক ও পর্যবেক্ষণ করার ধারাবাহিক প্রক্রিয়াকে মডেল মনিটরিং বলে।

প্রশ্ন ৩০: ডেপ্লয়মেন্টের পর মনিটরিং কেন জরুরি?

উত্তর: বাস্তব পৃথিবীর ডেটা প্রতিনিয়ত পরিবর্তিত হয়। ট্রেনিং সময়ের ডেটা আর প্রোডাকশন সময়ের ডেটার মধ্যে পার্থক্য দেখা দিলে মডেলের পারফরম্যান্স খারাপ হতে শুরু করে। মনিটরিং থাকলে পারফরম্যান্স ড্রপ, ডেটা অ্যানোমালি বা সিস্টেম এরর দ্রুত ধরে সমাধান করা যায়।

প্রশ্ন ৩১: একটি মডেল মনিটর না করলে কী কী সমস্যা হতে পারে?

উত্তর:

- **সাইলেন্ট ফেইলিউর (Silent Failure):** সিস্টেম কোনো এরর না দেখালেও ভুল প্রেডিকশন দিতে থাকবে।
- **ব্যবসায়িক ক্ষতি:** ভুল প্রেডিকশনের কারণে ভুল সিদ্ধান্ত গৃহীত হবে এবং কাস্টমার এক্সপেরিয়েন্স নষ্ট হবে।
- **মডেলের গুণমান হ্রাস:** সময়ের সাথে মডেল অপ্রাসঙ্গিক হয়ে পড়বে কিন্তু ডেভেলপারের অজান্তেই থেকে যাবে।

প্রশ্ন ৩২: একটি ডেপ্লয় করা NLP সিস্টেমে আপনি কী কী বিষয় মনিটর করবেন?

উত্তর: প্রধানত ৩টি ক্যাটাগরিতে মনিটর করা হয়:

- **সিস্টেম মেট্রিক্স:** Latency (ইনফারেন্স টাইম), Throughput (RPS), CPU/GPU usage, Memory leak, HTTP Error rate।
- **ডেটা ও মডেল মেট্রিক্স:** Data Drift, Concept Drift, Vocabulary Out-of-Vocabulary (OOV) rate, Sentence length distribution।
- **বিজনেস ও ফিডব্যাক মেট্রিক্স:** User explicit feedback (Like/Dislike), Click-through rate (CTR), Downstream task performance।

৯. মডেল আপডেট (Model Update)

প্রশ্ন ৩৩: মডেলের আপডেট বা রিট্রেনিং কেন প্রয়োজন?

উত্তর: ভাষা এবং ব্যবহারকারীদের আচরণ সময়ের সাথে পরিবর্তিত হয় (যেমন: নতুন স্ল্যাং, ট্রেন্ডিং কিওয়ার্ড, বা নতুন প্রোডাক্ট)। পুরনো ডেটাসেটে প্রশিক্ষিত মডেল নতুন ট্রেন্ড বা টার্মিনোলজি বুঝতে পারে না। তাই সিস্টেমকে প্রাসঙ্গিক ও নির্ভুল রাখতে নিয়মিত মডেল আপডেট দরকার।

প্রশ্ন ৩৪: Model Drift কী? (Data Drift vs Concept Drift)

উত্তর: সময়ের সাথে পরিবেশ বা পরিস্থিতির পরিবর্তনের ফলে লাইভ ডেটাতে মডেলের দক্ষতা ও নির্ভুলতা কমে যাওয়ার ঘটনাকে Model Drift বলে। এটি প্রধানত দুই প্রকার:

- **Data Drift (Covariate Shift):** ইনপুট ডেটার পরিসংখ্যানগত বিন্যাস বদলে যায়, কিন্তু ইনপুট ও আউটপুটের মূল সম্পর্ক একই থাকে। (যেমন: নতুন কোনো ফোন লঞ্চ হওয়ার পর চ্যাটবটে হঠাৎ একটি নির্দিষ্ট মডেল নিয়ে প্রশ্ন আসা)।
- **Concept Drift:** ইনপুট ও আউটপুট বা লেবেলের ভেতরের মূল সম্পর্কটিই বদলে যায়। (যেমন: মহামারীর আগে ও পরে 'মাস্ক' শব্দের অর্থ বা কেনাকাটার আচরণের পরিবর্তন)।

প্রশ্ন ৩৫: একটি মডেলকে কখন রিট্রেইন (Retrain) করা উচিত?

উত্তর: ৩টি প্রধান ট্রিগারের ওপর ভিত্তি করে মডেল রিট্রেন করা হয়:

1. **পারফরম্যান্স ড্রপ হলে (Metric Threshold):** মনিটরিংয়ে F1-Score বা Accuracy নির্ধারিত সীমার নিচে নেমে গেলে।
2. **নির্দিষ্ট সময় পরপর (Scheduled Retraining):** ব্যবসায়িক প্রয়োজন অনুসারে প্রতি সপ্তাহে, প্রতি মাসে বা প্রতি কোয়ার্টারে নতুন ডেটা দিয়ে রিট্রেন করা।
3. **বিশাল নতুন ডেটা যুক্ত হলে (Data Volume Threshold):** সিস্টেমে পর্যাপ্ত পরিমাণ (যেমন: ৫০,০০০+) নতুন লেবেলযুক্ত লাইভ ডেটা জমা হলে।

প্রশ্ন ৩৬: একটি নতুন মডেল বর্তমান (Current) মডেলের চেয়ে ভালো কি না তা কীভাবে নির্ধারণ করবেন?

উত্তর: ধাপে ধাপে দুটি উপায়ে পরীক্ষা ও সিদ্ধান্ত নেওয়া হয়:

- **অফলাইন ইভালুয়েশন (Offline Evaluation):** নতুন ও বর্তমান মডেল দুটিকেই একটি সাম্প্রতিক Gold-Standard holdout test-set এর ওপর রান করে Precision, Recall, F1-Score তুলনা করা হয়।
- **অনলাইন ইভালুয়েশন — A/B Testing (Online Evaluation):** রিয়েল ট্রাফিকের ১০% নতুন মডেল (Model B) এবং ৯০% পুরনো মডেলে (Model A) পাঠিয় তাদের লাইভ লেটেন্সি, ইউজার স্যাটিসফ্যাকশন ও কনভার্সন রেট তুলনা করা হয়। যদি B ভালো পারফর্ম করে, তবে ১০০% ট্রাফিক B-তে শিফট করা হয়।
- **Shadow Deployment:** লাইভ ট্রাফিকের কপি ব্যাকগ্রাউন্ডে নতুন মডেলে পাঠানো হয় কিন্তু ইউজারকে আউটপুট দেখানো হয় না, কেবল পারফরম্যান্স ও লেটেন্সি মেপে দেখা হয়।