NLP & Word Embeddings Interview Guide

প্রশ্নোত্তর এবং বিশদ ইন্টারভিউ প্রস্তুতির সম্পূর্ণ গাইড (Bengali Edition)

প্রশ্ন ১: Skip-gram মডেল এবং পেয়ার জেনারেশন

ধরা যাক বাক্যটি হলো: **"I love machine learning today"**। উইন্ডো সাইজ (Window Size) = 1 হলে:

১. ইনপুট-টার্গেট পেয়ারগুলি (Input-Target Pairs):

উইন্ডো সাইজ ১ মানে প্রতিটি সেন্ট্রাল শব্দের বাম ও ডান পাশের ১টি করে শব্দ কনটেক্সট হিসেবে গণ্য হবে:

- **I** → (I, love)
- **love** → (love, I), (love, machine)
- **machine** → (machine, love), (machine, learning)
- **learning** → (learning, machine), (learning, today)
- **today** → (today, learning)

২. "I" প্রেডিক্ট করার সময় ইনপুট শব্দ কোনটি?

যখন টার্গেট শব্দ **"I"**, তখন তার কন্টেক্সট বা ইনপুট শব্দ হলো **"love"**। (পেয়ার: love → I)

৩. "machine" প্রেডিক্ট করার সময় ইনপুট শব্দ কোনটি?

যখন টার্গেট শব্দ **"machine"**, তখন তার কন্টেক্সট বা ইনপুট শব্দ হতে পারে **"love"** অথবা **"learning"**।

🎯 **Interview Pro Tip:** ইন্টারভিউতে Skip-gram নিয়ে প্রশ্ন করলে উইন্ডো সাইজ কীভাবে পেয়ার তৈরি করে তা ডায়াগ্রাম এঁকে বুঝিয়ে বলুন। মনে রাখবেন, Skip-gram এ টার্গেট শব্দ থেকে কন্টেক্সট প্রেডিক্ট করা হয়।

প্রশ্ন ২: One-Hot Encoding এর পরিবর্তে Word2Vec কেন ব্যবহার করা হয়?

নিচে তিনটি মূল ডাইমেনশনে তুলনামূলক আলোচনা করা হলো:

তুলনামূলক বিশ্লেষণ টেবিল:

বৈশিষ্ট্য (Criteria)	One-Hot Encoding	Word2Vec (Dense Embedding)
ডাইমেনশন্যালিটি (Dimensionality)	অতি উচ্চ (Vocabulary size N, যেমন: ৫০,০০০+)	কম ও ফিক্সড (সাধারণত ১০০ থেকে ৩০০ ডাইমেনশন)
শব্দার্থিক সাদৃশ্য (Similarity)	সাদৃশ্য বোঝাতে ব্যর্থ (Dot product সবসময় ০ হয়)	Cosine Similarity এর মাধ্যমে কাছাকাছি অর্থ প্রকাশ করে
মেমরি ব্যবহার (Memory Usage)	অত্যন্ত বেশি ও স্পার্স (Sparse) ম্যাট্রিক্স	খুব কম এবং ডেন্স (Dense) ভেক্টর

প্রশ্ন ৩: CBOW বনাম Skip-gram এবং কন্টেক্সট প্রেডিকশন

Word2Vec এর দুটি আর্কিটেকচারের মূল পার্থক্য নিচে দেওয়া হলো:

- CBOW **Continuous Bag of Words:** এটি কন্টেক্সট শব্দগুলো থেকে টার্গেট শব্দ প্রেডিক্ট করে। (যেমন: "I ___ machine" → love)
- Skip-gram **Skip-gram Model:** এটি একটি টার্গেট শব্দ থেকে কন্টেক্সট শব্দগুলো প্রেডিক্ট করে। (যেমন: "love" → I, machine)
- **কোনটি কন্টেক্সট প্রেডিক্ট করে? Skip-gram মডেল** টার্গেট শব্দ থেকে কন্টেক্সট শব্দ প্রেডিক্ট করে। অন্যদিকে CBOW কন্টেক্সট থেকে টার্গেট প্রেডিক্ট করে।

🎯 **Interview Summary:** CBOW দ্রুত কাজ করে এবং ঘন ঘন আসা শব্দের জন্য ভালো, তবে Skip-gram বিরল শব্দ (Rare words) এবং ছোট ডেটাসেটের ক্ষেত্রে অনেক বেশি নিখুঁত ফলাফল দেয়।